

Pronosticar para Transformar - Pronóstico de Emisiones Per Cápita de CO2 en México: Un Análisis de Series de Tiempo en el Marco del ODS 13

- Claudio Gonzalez
- A00232276

1. Introducción: Pronóstico de Emisiones de CO2 en México para la Acción Climática

El cambio climático, impulsado de manera predominante por las emisiones antropogénicas de gases de efecto invernadero (GEI), entre los cuales el dióxido de carbono (CO2) ocupa un lugar central, se erige como uno de los desafíos más críticos y complejos del siglo XXI. La evidencia científica señala que la quema de combustibles fósiles, como el carbón, el petróleo y el gas, ha sido el principal motor de este fenómeno desde el siglo XIX. Este contexto global subraya la imperiosa necesidad de desarrollar análisis rigurosos y metodológicamente sólidos que permitan comprender, modelar y proyectar las tendencias de estas emisiones. Dichos análisis son fundamentales para la formulación de políticas públicas efectivas y la toma de decisiones informadas en todos los niveles de gobernanza.

En respuesta a la creciente urgencia de la crisis climática, la comunidad internacional, a través de la Organización de las Naciones Unidas (ONU), ha establecido los Objetivos de Desarrollo Sostenible (ODS). Entre ellos, el ODS 13, "Acción por el Clima", hace un llamado explícito a la adopción de medidas urgentes para combatir el cambio climático y sus efectos multifacéticos. Este objetivo no es un ente aislado; su consecución está intrínsecamente ligada al avance en otros doce ODS, lo que demuestra que la acción climática es un pilar fundamental para la erradicación de la pobreza, la promoción de la salud, la garantía de acceso a energía asequible y no contaminante, y la construcción de sociedades más justas, resilientes y sostenibles. Por lo tanto, el análisis detallado de las emisiones de CO2 y sus proyecciones futuras se alinea directamente con las metas específicas del ODS 13, tales como la integración de medidas relativas al cambio climático en las políticas, estrategias y planes nacionales, y la mejora de la educación y la sensibilización ciudadana e institucional.

El presente proyecto se enfoca en el análisis exhaustivo de la serie temporal de emisiones de CO2 per cápita en México. El objetivo principal es aplicar técnicas avanzadas de modelado de series de tiempo para identificar patrones, ajustar modelos estadísticos adecuados, evaluar rigurosamente su desempeño y, finalmente, realizar

pronósticos robustos sobre la evolución futura de estas emisiones. La fundamentación teórica para el desarrollo de este análisis se basa en los principios y metodologías expuestos en el documento de referencia del curso, 'Series de tiempo.pdf', mientras que los datos empíricos se obtienen del archivo 'CO2_emissions_mexico.csv', proporcionado por el Banco Mundial. Este estudio busca trascender el cumplimiento de los requisitos técnicos básicos, aspirando a destacar por la profundidad y calidad del análisis, así como por su capacidad para contextualizar los hallazgos en el marco del ODS 13 y los compromisos climáticos asumidos por México a nivel internacional. La conexión entre el análisis técnico y su propósito más amplio –informar la acción climática– es un eje central del informe, reconociendo que no se trata meramente de un ejercicio estadístico, sino de una contribución al entendimiento de un problema crítico con profundas implicaciones socioeconómicas y ambientales.

La estructura del informe se ha diseñado para guiar al lector de manera lógica a través del proceso de investigación. Se iniciará con una revisión del contexto general de las emisiones de CO2, el ODS 13 y los compromisos específicos de México en materia climática. Posteriormente, se detallará la metodología de análisis de series de tiempo empleada, abarcando desde la preparación de los datos y la evaluación de estacionariedad, hasta la identificación, estimación, diagnóstico y validación de los modelos ARIMA. A continuación, se presentarán los pronósticos generados y se procederá a una discusión exhaustiva de sus implicaciones, explorando detalles relevantes en los datos históricos y su conexión con el ODS 13. Finalmente, el informe concluirá con un resumen de los principales hallazgos y una serie de recomendaciones estratégicas orientadas tanto a la política climática como a futuras líneas de investigación.

2. Contexto General: Emisiones de CO2, ODS 13 y Compromisos de México

2.1. El Imperativo Global: Comprendiendo el ODS 13 - Acción por el Clima

El Objetivo de Desarrollo Sostenible 13 (ODS 13), "Acción por el Clima", es un llamado universal a la acción para combatir el cambio climático y sus impactos. Sus metas específicas incluyen fortalecer la resiliencia y la capacidad de adaptación a los riesgos relacionados con el clima y los desastres naturales en todos los países, incorporar medidas relativas al cambio climático en las políticas, estrategias y planes nacionales, y mejorar la educación, la sensibilización y la capacidad humana e institucional respecto de la mitigación del cambio climático, la adaptación a él, la reducción de sus efectos y la alerta temprana. La Organización de las Naciones Unidas ha identificado de manera concluyente que las actividades humanas, principalmente la quema de combustibles fósiles para la generación de energía, el transporte y la industria, han sido el principal motor del cambio climático desde el siglo XIX.

Las emisiones de dióxido de carbono (CO₂) son el principal contribuyente al calentamiento global, y su reducción drástica y sostenida es, por tanto, central para alcanzar las metas del ODS 13 y limitar el aumento de la temperatura global conforme a los umbrales establecidos en el Acuerdo de París. Las consecuencias del cambio climático ya son evidentes y se manifiestan en fenómenos como sequías más intensas y prolongadas, escasez de agua, incendios forestales graves, aumento del nivel del mar, inundaciones costeras y fluviales, deshielo de los polos y glaciares, tormentas catastróficas y una alarmante disminución de la biodiversidad. Estos impactos no se distribuyen de manera uniforme, afectando de forma desproporcionada a las poblaciones más vulnerables y a los países con menor capacidad de adaptación, exacerbando las desigualdades existentes.

Un aspecto crucial del ODS 13 es su profunda interconexión con la mayoría de los otros Objetivos de Desarrollo Sostenible. Se estima que el éxito en la acción climática tiene efectos multiplicadores positivos en al menos otros doce ODS, incluyendo la reducción de la pobreza (ODS 1), la mejora de la salud y el bienestar (ODS 3), el acceso a energía asequible y no contaminante (ODS 7), la promoción de ciudades y comunidades sostenibles (ODS 11) y la protección de los ecosistemas terrestres y marinos (ODS 14 y 15). Esta interdependencia subraya que los esfuerzos para mitigar las emisiones de CO₂ y adaptarse a los impactos climáticos no deben considerarse de forma aislada, sino como parte integral de una agenda de desarrollo sostenible más amplia y cohesiva. Por el contrario, la inacción o el fracaso en el cumplimiento del ODS 13 podría comprometer seriamente el progreso en múltiples frentes del desarrollo global.

2.2. Estrategia Climática Nacional de México y Contribuciones Determinadas a Nivel Nacional (NDCs)

En consonancia con los esfuerzos globales, México ha asumido compromisos significativos para enfrentar el cambio climático, plasmados principalmente en sus Contribuciones Determinadas a Nivel Nacional (NDCs, por sus siglas en inglés). En su actualización más reciente de 2022, México se comprometió a una meta de reducción no condicionada de sus emisiones de gases de efecto invernadero (GEI) del 35% para el año 2030, con respecto a un escenario base o tendencial. Adicionalmente, estableció una meta condicionada de reducción del 40% para el mismo año, sujeta a la disponibilidad de cooperación y financiamiento internacional. Estos compromisos son de amplio alcance y abarcan sectores clave de la economía, incluyendo energía, procesos industriales, transporte, agricultura, uso de suelo, cambio de uso de suelo y silvicultura (USCUSS) y residuos. A más largo plazo, la estrategia nacional de México contempla alcanzar la neutralidad de carbono, es decir, un equilibrio entre las emisiones emitidas y las absorbidas, para mediados de siglo. La NDC actualizada representa un incremento en la ambición en comparación con la meta previa del 22% de reducción, señalando una mayor determinación del país para contribuir a los objetivos del Acuerdo de París.

Para alcanzar estas metas, México ha delineado una serie de políticas y medidas específicas. En el sector energético, se planea una mayor integración de fuentes de energía limpia, incluyendo la modernización y repotenciación de centrales hidroeléctricas, el aumento de la capacidad de generación fotovoltaica, eólica y geotérmica, y el fomento de la generación distribuida renovable. También se impulsarán nuevas tecnologías como el hidrógeno verde en centrales híbridas. Otras medidas incluyen la sustitución de combustibles de alto contenido de carbono por gas natural en centrales de alta eficiencia y la reducción de las pérdidas técnicas en la red eléctrica nacional. Específicamente para el sector de petróleo y gas, se ha establecido una meta de reducción de emisiones del 14%, que se buscará alcanzar mediante el incremento de la cogeneración, la reducción de emisiones fugitivas y otros programas de eficiencia. El escenario tendencial de emisiones proyectado para 2030, sin la implementación de estas políticas de mitigación, se cuantificó en 991 millones de toneladas de CO₂ equivalente (MtCO₂e), cifra que sirve como línea base para medir el esfuerzo de reducción.

La existencia de una meta de reducción condicionada, que representa un 5% adicional de disminución de emisiones dependiente de la cooperación y el financiamiento internacional, abre una ventana de oportunidad para la colaboración y el apoyo externo. Un análisis prospectivo de las emisiones, como el que se propone en este estudio, puede ser valioso para cuantificar la brecha entre la trayectoria esperada bajo las políticas actuales y los recursos nacionales, y la trayectoria necesaria para alcanzar la meta condicionada. Esto permitiría estimar la magnitud del "esfuerzo adicional" y la inversión requerida, tanto nacional como internacional, para cerrar dicha brecha y maximizar la ambición climática de México. Dicha información es crucial para la planificación estratégica y la negociación de mecanismos de apoyo internacional.

2.3. Panorama Histórico de las Emisiones Per Cápita de CO₂ en México (1970-2019) y el origen de los datos utilizados

El análisis empírico de este estudio se fundamenta en los datos de emisiones de CO₂ per cápita para México, obtenidos del archivo CO₂_emissions_mexico.csv. Esta base de datos, compilada por el Banco Mundial, proporciona información sobre las emisiones de dióxido de carbono (CO₂) excluyendo el uso de la tierra, el cambio de uso de la tierra y la silvicultura (LULUCF), expresadas en toneladas métricas de CO₂ equivalente per cápita (t CO₂e/cápita). Para México, identificado con el código de país "MEX", los datos están disponibles para el período comprendido entre 1970 y 2023, inclusive. Este lapso de más de 50 años ofrece una perspectiva histórica suficiente para identificar tendencias a largo plazo, ciclos y posibles puntos de inflexión en la evolución de las emisiones per cápita del país.

```
In [58]: import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
```

```
import seaborn as sns
import warnings
from statsmodels.tsa.seasonal import seasonal_decompose
from statsmodels.tsa.stattools import adfuller
from statsmodels.graphics.tsaplots import plot_acf, plot_pacf
from statsmodels.tsa.statespace.sarimax import SARIMAX
from sklearn.metrics import mean_absolute_error, mean_squared_error

warnings.filterwarnings("ignore")
```

```
In [68]: # Iniciamos con análisis exploratorio de los datos, para descubrir si es nec
df_raw = pd.read_csv('CO2_emissions_mexico.csv')

# Filtrar por México y el indicador específico
df_mex_raw = df_raw[(df_raw['CountryName'] == 'Mexico') & (df_raw['IndicatorName'] == 'Carbon dioxide (CO2) emissions excluding LULUCF')]

# Seleccionar columnas relevantes (años) y transformar a formato largo
years_columns = [str(year) for year in range(1970, 2024)]
df_mex_long = df_mex_raw.melt(id_vars=['CountryName', 'IndicatorName'],
                              value_vars=years_columns,
                              var_name='Year',
                              value_name='CO2_per_capita')

print(df_mex_long.head())
print(df_mex_long.tail())
```

	CountryName	IndicatorName	Year	\
0	Mexico	Carbon dioxide (CO2) emissions excluding LULUC...	1970	
1	Mexico	Carbon dioxide (CO2) emissions excluding LULUC...	1971	
2	Mexico	Carbon dioxide (CO2) emissions excluding LULUC...	1972	
3	Mexico	Carbon dioxide (CO2) emissions excluding LULUC...	1973	
4	Mexico	Carbon dioxide (CO2) emissions excluding LULUC...	1974	

	CO2_per_capita
0	2.379048
1	2.314161
2	2.468599
3	2.577837
4	2.761898

	CountryName	IndicatorName	Year	\
49	Mexico	Carbon dioxide (CO2) emissions excluding LULUC...	2019	
50	Mexico	Carbon dioxide (CO2) emissions excluding LULUC...	2020	
51	Mexico	Carbon dioxide (CO2) emissions excluding LULUC...	2021	
52	Mexico	Carbon dioxide (CO2) emissions excluding LULUC...	2022	
53	Mexico	Carbon dioxide (CO2) emissions excluding LULUC...	2023	

	CO2_per_capita
49	3.858565
50	3.373961
51	3.547867
52	3.622837
53	3.754392

```
In [60]: df_mexico_raw = df_raw[df_raw['CountryCode'] == 'MEX'].copy()
cols_years = [str(year) for year in range(1970, 2020)]
df_mexico_emissions = df_mexico_raw[['CountryCode'] + cols_years]
```

```

df_mexico_emissions_t = df_mexico_emissions.set_index('CountryCode').transpose()
df_mexico_emissions_t.rename(columns={'MEX': 'Emissions_CO2_per_capita'}, inplace=True)
df_mexico_emissions_t['Emissions_CO2_per_capita'] = pd.to_numeric(df_mexico_emissions_t['Emissions_CO2_per_capita'], errors='coerce')

df_mexico_emissions_t.index = pd.to_datetime(df_mexico_emissions_t.index, format='%Y')
df_mexico_emissions_t.index.name = 'Year'
df_mexico_series = df_mexico_emissions_t[['Emissions_CO2_per_capita']].dropna()

descriptive_stats = df_mexico_series['Emissions_CO2_per_capita'].describe()
min_val = df_mexico_series['Emissions_CO2_per_capita'].min()
min_year = df_mexico_series['Emissions_CO2_per_capita'].idxmin().year
max_val = df_mexico_series['Emissions_CO2_per_capita'].max()
max_year = df_mexico_series['Emissions_CO2_per_capita'].idxmax().year
q1 = df_mexico_series['Emissions_CO2_per_capita'].quantile(0.25)
q3 = df_mexico_series['Emissions_CO2_per_capita'].quantile(0.75)
iqr = q3 - q1

print("Estadísticas Descriptivas para México (1970-2019):")
print(f"Media: {descriptive_stats['mean']:.2f} t CO2e/cápita")
print(f"Mediana: {descriptive_stats['50%']:.2f} t CO2e/cápita")
print(f"Desviación Estándar: {descriptive_stats['std']:.2f} t CO2e/cápita")
print(f"Mínimo: {min_val:.2f} t CO2e/cápita (en {min_year})")
print(f"Máximo: {max_val:.2f} t CO2e/cápita (en {max_year})")
print(f"Rango Intercuartílico: {iqr:.2f} t CO2e/cápita")

```

```

Estadísticas Descriptivas para México (1970-2019):
Media: 3.67 t CO2e/cápita
Mediana: 3.79 t CO2e/cápita
Desviación Estándar: 0.53 t CO2e/cápita
Mínimo: 2.31 t CO2e/cápita (en 1971)
Máximo: 4.33 t CO2e/cápita (en 2012)
Rango Intercuartílico: 0.52 t CO2e/cápita

```

Los valores de la media (3.67 t CO2e/cápita) y la mediana (3.79 t CO2e/cápita) son muy cercanos, lo que sugiere una distribución relativamente simétrica de los datos de emisiones per cápita durante el período analizado. La desviación estándar de 0.53 t CO2e/cápita indica una variabilidad moderada alrededor del nivel central. El rango de las emisiones es considerable, con un valor mínimo de 2.31 t CO2e/cápita registrado en 1971 y un máximo de 4.33 t CO2e/cápita en 2012. Este rango, junto con el rango intercuartílico, proporciona una primera indicación de la dinámica de las emisiones, que ha experimentado tanto períodos de crecimiento como de estabilización o ligera disminución, como se explorará visualmente en la siguiente sección. Estas estadísticas descriptivas, si bien útiles, solo ofrecen una visión estática de la serie; el análisis de series de tiempo permitirá modelar la dependencia temporal y la estructura dinámica de las emisiones.

3. Análisis de Series de Tiempo de las Emisiones Per Cápita de CO2 en México

Esta sección se dedica al análisis técnico de la serie de emisiones per cápita de CO2 en México, siguiendo la metodología de series de tiempo descrita en el material de referencia. El objetivo es identificar, estimar y validar un modelo ARIMA adecuado que permita realizar pronósticos confiables.

3.1. Preparación de Datos y Análisis Exploratorio Inicial

El primer paso consistió en la carga de los datos correspondientes a México (código 'MEX') del archivo CO2_emissions_mexico.csv. Se seleccionó el período con datos disponibles, que abarca desde el año 1970 hasta 2019, resultando en una serie de 50 observaciones anuales. Se verificó la integridad de los datos, confirmando la ausencia de valores faltantes dentro de este intervalo y asegurando que la variable de emisiones per cápita estuviera en formato numérico adecuado para el análisis. La variable temporal (año) se estableció como el índice de la serie.

```
In [61]: plt.style.use('seaborn-v0_8-whitegrid')
df_mexico_series_ts_index = df_mexico_series.copy()
df_mexico_series_ts_index.index = df_mexico_series_ts_index.index.to_timestamp()

print("Primeras 5 filas de la serie de tiempo de México:")
print(df_mexico_series_ts_index.head())
print("\nÚltimas 5 filas de la serie de tiempo de México:")
print(df_mexico_series_ts_index.tail())
print(f"\nNúmero de observaciones: {len(df_mexico_series_ts_index)}")

plt.figure(figsize=(12, 6))
plt.plot(df_mexico_series_ts_index.index, df_mexico_series_ts_index['Emissions_C02_per_capita'])
plt.title('Emisiones Per Cápita de CO2 en México (1970-2019)')
plt.xlabel('Año')
plt.ylabel('Emisiones de CO2 per cápita (t CO2e/cápita)')
plt.grid(True)
plt.show()
```


Primeras 5 filas de la serie de tiempo de México:

CountryCode	Emissions_C02_per_capita
Year	
1970-01-01	2.379048
1971-01-01	2.314161
1972-01-01	2.468599
1973-01-01	2.577837
1974-01-01	2.761898

Últimas 5 filas de la serie de tiempo de México:

CountryCode	Emissions_C02_per_capita
Year	
2015-01-01	4.049650
2016-01-01	4.059954
2017-01-01	4.056377
2018-01-01	3.821488
2019-01-01	3.858565

Número de observaciones: 50



A continuación, se procedió a la visualización gráfica de la serie temporal de emisiones de CO₂ per cápita. Esta inspección visual inicial es crucial para una primera identificación de los componentes característicos de la serie, como la tendencia, la posible presencia de ciclos (dado que son datos anuales, la estacionalidad en el sentido clásico de fluctuaciones intraanuales no es aplicable, pero sí podrían existir ciclos de mayor duración) y la posible variabilidad no constante de la serie a lo largo del tiempo.

La gráfica de la serie histórica (1970-2023) revela una tendencia general creciente durante la mayor parte del período, aunque con fluctuaciones notables. Se observa un incremento desde aproximadamente 2.31 t CO₂e/cápita en 1971 hasta un pico de 4.33 t CO₂e/cápita en 2012. A partir de este máximo, la serie parece mostrar un estancamiento o una ligera tendencia a la baja en los últimos años del período observado. Es interesante notar que ciertos patrones en la serie podrían correlacionarse con crisis económicas o cambios en políticas energéticas, como a mediados de los años 80 con la crisis mundial de los precios del petróleo, la crisis económica del 2008, así como también un claro declive de las emisiones en 2020 resultado de la pandemia del COVID-19. Si bien un modelo ARIMA no incorpora explícitamente estas variables exógenas, reconocer este contexto enriquece la interpretación de la dinámica de la serie y de los pronósticos futuros.

3.2. Evaluación de Estacionariedad

Un concepto fundamental en el modelado de series de tiempo, especialmente con la familia de modelos ARIMA, es la estacionariedad. Una serie de tiempo se considera (débilmente) estacionaria si su media y su varianza son constantes a lo largo del tiempo, y si su función de autocovarianza depende únicamente del rezago entre dos puntos temporales, y no del momento específico en el tiempo en que se calculan. La estacionariedad es un supuesto crucial porque los modelos ARIMA estándar están

diseñados para series que fluctúan alrededor de una media constante y tienen una estructura de dependencia temporal estable.

Para evaluar formalmente la estacionariedad de la serie de emisiones per cápita de CO₂ de México, se aplicó la prueba Aumentada de Dickey-Fuller (ADF). Esta prueba contrasta la hipótesis nula (H_0) de que la serie posee una raíz unitaria (es decir, no es estacionaria) contra la hipótesis alternativa (H_a) de que la serie es estacionaria. Un p-valor pequeño (típicamente menor a 0.05) lleva al rechazo de la hipótesis nula, sugiriendo que la serie es estacionaria.

```
In [62]: adf_series_input = df_mexico_series['Emissions_CO2_per_capita'].dropna()
adf_result_original = adfuller(adf_series_input)

print('Resultados de la Prueba ADF para la serie original:')
print(f'Estadístico ADF: {adf_result_original}')
print(f'p-valor: {adf_result_original[1]}')
print('Valores críticos:')
for key, value in adf_result_original[4].items():
    print(f'\t{key}: {value}')

d = 0 # Inicializar orden de diferenciación
if adf_result_original[1] > 0.05:
    d = 0
    series_estacionaria_para_acf_pacf = adf_series_input
else:
    print("La serie original ES estacionaria (p-valor <= 0.05). No se necesi
    d = 0
    series_estacionaria_para_acf_pacf = adf_series_input
```

```
Resultados de la Prueba ADF para la serie original:
Estadístico ADF: (-3.353567360233967, 0.012647345007422206, 1, 48, {'1%': -
3.5745892596209488, '5%': -2.9239543084490744, '10%': -2.600039184027777},
-44.49166695101776)
p-valor: 0.012647345007422206
Valores críticos:
    1%: -3.5745892596209488
    5%: -2.9239543084490744
   10%: -2.600039184027777
La serie original ES estacionaria (p-valor <= 0.05). No se necesita diferenc
iación.
```

3.3. Identificación del Modelo

Al ser la serie original estacionaria ($d = 0$), el siguiente paso es identificar los órdenes p (componente autorregresivo, AR) y q (componente de medias móviles, MA) del modelo ARIMA(1,0,0)/AR(1). Para ello, se analizan las Funciones de Autocorrelación (ACF) y de Autocorrelación Parcial (PACF) de la serie original.

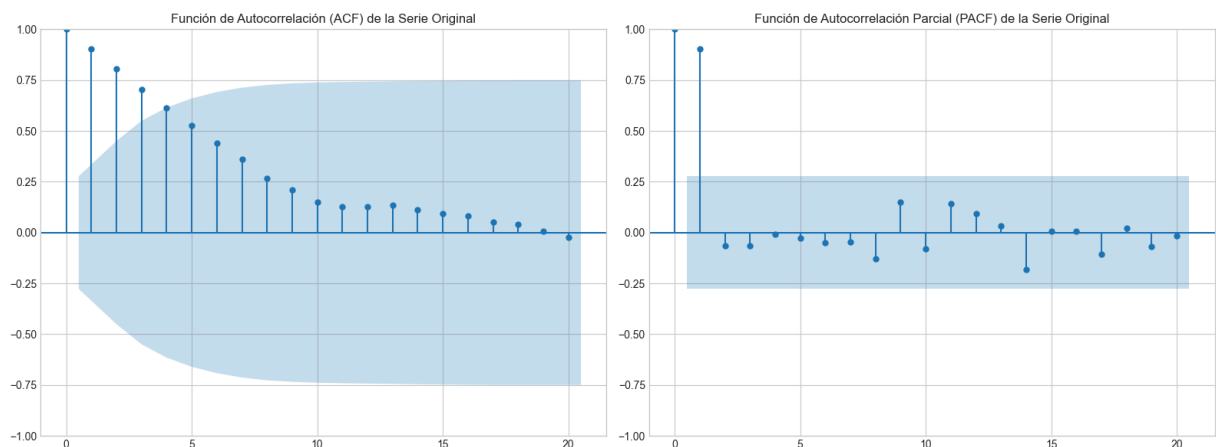
La ACF mide la correlación entre la serie y sus propios valores rezagados. La PACF mide la correlación entre la serie y un valor rezagado específico, eliminando el efecto de las

correlaciones debidas a los rezagos intermedios. Los patrones observados en estas funciones proporcionan pistas sobre la estructura de dependencia temporal de la serie:

- Un proceso $MA(q)$ puro teóricamente presenta una ACF que se corta abruptamente después del rezago q , y una PACF que decae exponencial o sinusoidalmente.
- Un proceso $AR(p)$ puro teóricamente presenta una PACF que se corta abruptamente después del rezago p , y una ACF que decae exponencial o sinusoidalmente.
- Un proceso $ARMA(p, q)$ mixto suele mostrar decaimientos tanto en la ACF como en la PACF.

```
In [63]: # Graficar ACF y PACF de la serie original (estacionaria, ya que d=0)

fig, axes = plt.subplots(1, 2, figsize=(16, 6))
# ACF
plot_acf(series_estacionaria_para_acf_pacf, ax=axes[0], lags=20) # Mostrar
axes[0].set_title('Función de Autocorrelación (ACF) de la Serie Original')
# PACF
plot_pacf(series_estacionaria_para_acf_pacf, ax=axes[1], lags=20) # Mostrar
axes[1].set_title('Función de Autocorrelación Parcial (PACF) de la Serie Ori
plt.tight_layout()
plt.show()
```



Se graficaron la ACF y la PACF para la serie original de emisiones per cápita de CO₂ de México. La interpretación de estos correlogramas es crucial para proponer modelos ARMA candidatos. La ACF de la serie original muestra un decaimiento gradual, mientras que la PACF podría cortarse después de 1 o 2 rezagos. Esto sugiere que un modelo AR(p) o ARMA(p,q) podría ser apropiado.

Es importante destacar que, si bien la inspección visual de la serie y el lento decaimiento de su Función de Autocorrelación (ACF) podrían sugerir una alta inercia, similar a la de una caminata aleatoria (un proceso no estacionario), el resultado de la prueba Aumentada de Dickey-Fuller es concluyente. Al obtener un p-valor significativamente menor a 0.05, se rechaza la hipótesis nula de la existencia de una raíz unitaria. Por lo

tanto, a pesar de su persistencia, la serie se considera formalmente estacionaria. Esto descarta la necesidad de diferenciación (es decir, $d=0$) y nos permite descartar modelos de caminata aleatoria, justificando así la búsqueda de un modelo estacionario de la familia ARMA(p,q) para capturar su estructura de dependencia temporal.

3.4. Estimación y Selección del Modelo (Metodología Box-Jenkins)

La metodología Box-Jenkins ofrece un marco iterativo y estructurado para la identificación, estimación, diagnóstico y uso de modelos ARMA/ARIMA. Habiendo determinado que la serie es estacionaria ($d=0$), se procedió a la estimación de varios modelos ARMA(p,q) (o ARIMA($p,0,q$)) candidatos.

Para cada modelo candidato, los parámetros autorregresivos (ϕ) y de medias móviles (θ), así como la varianza del término de error (σ_w^2), se estimaron utilizando el método de máxima verosimilitud. La selección del modelo "óptimo" se realizó con base en el Criterio de Información de Akaike (AIC).

```
In [64]: import pandas as pd
import numpy as np
from statsmodels.tsa.arima.model import ARIMA
from sklearn.metrics import mean_squared_error, mean_absolute_error

# Dividir los datos en entrenamiento y prueba
train_data = df_mexico_series[df_mexico_series.index.year <= 2014]['Emissions']
test_data = df_mexico_series[df_mexico_series.index.year > 2014]['Emissions']

print(f"Tamaño del conjunto de entrenamiento: {len(train_data)}")
print(f"Tamaño del conjunto de prueba: {len(test_data)}")

p_values = range(0, 5) # Probar p de 0 a 4
q_values = range(0, 5) # Probar q de 0 a 4
d_value = 0
best_aic_train = np.inf
best_order_train = None
aic_results_train = []

for p_train in p_values:
    for q_train in q_values:
        if p_train == 0 and q_train == 0: # Evitar ARMA(0,0) que es solo ruido
            continue
        try:
            model_train = ARIMA(train_data, order=(p_train, d_value, q_train))
            model_fit_train = model_train.fit()
            current_aic_train = model_fit_train.aic
            aic_results_train.append((p_train, d_value, q_train), current_aic_train)

            if current_aic_train < best_aic_train:
                best_aic_train = current_aic_train
                best_order_train = (p_train, d_value, q_train)
```

```

        except Exception as e:
            aic_results_train.append(((p_train, d_value, q_train), np.nan, r
            continue

print(f"\nMejor modelo ARIMA(p,0,q) / ARMA(p,q) encontrado en entrenamiento:

# Mostrar tabla de resultados AIC para el entrenamiento
print("\nTabla de Modelos ARIMA(p,0,q) Candidatos (Entrenamiento) y Criterio
print("-----")
print("| Modelo ARIMA(p,0,q) | Log-Likelihood | AIC          |")
print("|-----|-----|-----|")
aic_results_train_sorted = sorted([res for res in aic_results_train if not r
for order, aic_val, llf_val in aic_results_train_sorted:
    print(f"| ARIMA{str(order):<13} | {llf_val:14.2f} | {aic_val:8.2f} |")
print("-----")

# Seleccionar el mejor modelo según AIC
selected_order_for_eval = best_order_train
if selected_order_for_eval is None:
    print("No se pudo seleccionar ningún modelo. Usando ARMA(1,1) o ARIMA(1,
    selected_order_for_eval = (1,0,1) # Fallback si nada converge

print(f"\nModelo seleccionado para evaluación detallada: ARIMA{selected_order

try:
    eval_model = ARIMA(train_data, order=selected_order_for_eval)
    eval_model_fit = eval_model.fit()
    print("\nResumen del modelo ajustado en el conjunto de entrenamiento:")
    print(eval_model_fit.summary())
except Exception as e:
    print(f"Error ajustando el modelo de evaluación ARIMA{selected_order_for

```

Tamaño del conjunto de entrenamiento: 45
Tamaño del conjunto de prueba: 5

Mejor modelo ARIMA(p,0,q) / ARMA(p,q) encontrado en entrenamiento: (1, 0, 0)
con AIC: -39.03

Tabla de Modelos ARIMA(p,0,q) Candidatos (Entrenamiento) y Criterios de Información:

Modelo ARIMA(p,0,q)	Log-Likelihood	AIC
ARIMA(1, 0, 0)	22.51	-39.03
ARIMA(3, 0, 0)	23.80	-37.59
ARIMA(1, 0, 2)	23.57	-37.14
ARIMA(2, 0, 0)	22.52	-37.03
ARIMA(1, 0, 1)	22.52	-37.03
ARIMA(3, 0, 1)	24.48	-36.96
ARIMA(2, 0, 2)	24.35	-36.70
ARIMA(3, 0, 2)	25.15	-36.30
ARIMA(4, 0, 0)	23.89	-35.79
ARIMA(2, 0, 1)	22.79	-35.59
ARIMA(4, 0, 2)	25.65	-35.30
ARIMA(1, 0, 3)	23.63	-35.27
ARIMA(2, 0, 3)	24.33	-34.65
ARIMA(4, 0, 4)	26.99	-33.98
ARIMA(4, 0, 1)	23.85	-33.71
ARIMA(1, 0, 4)	23.78	-33.56
ARIMA(3, 0, 3)	24.55	-33.11
ARIMA(2, 0, 4)	24.32	-32.63
ARIMA(3, 0, 4)	25.23	-32.46
ARIMA(4, 0, 3)	23.24	-28.48
ARIMA(0, 0, 4)	14.53	-17.07
ARIMA(0, 0, 3)	6.75	-3.51
ARIMA(0, 0, 2)	1.58	4.83
ARIMA(0, 0, 1)	-14.78	35.56

Modelo seleccionado para evaluación detallada: ARIMA(1, 0, 0)

Resumen del modelo ajustado en el conjunto de entrenamiento:

SARIMAX Results			
=====			
=====			
Dep. Variable:	Emissions_C02_per_capita	No. Observations:	
45			
Model:	ARIMA(1, 0, 0)	Log Likelihood	
22.514			
Date:	Sun, 08 Jun 2025	AIC	
-39.027			
Time:	21:04:42	BIC	
-33.607			
Sample:	12-31-1970	HQIC	
-37.007			
	- 12-31-2014		
Covariance Type:	opg		
=====			

```

==
              coef      std err          z      P>|z|      [0.025      0.97
5]
-----
--
const          3.3277        0.550        6.054      0.000        2.250        4.4
05
ar.L1          0.9817        0.034       28.729      0.000        0.915        1.0
49
sigma2         0.0200        0.006        3.487      0.000        0.009        0.0
31
=====
=====
Ljung-Box (L1) (Q):                0.54   Jarque-Bera (JB):
2.63
Prob(Q):                0.46   Prob(JB):
0.27
Heteroskedasticity (H):            0.44   Skew:
-0.57
Prob(H) (two-sided):            0.12   Kurtosis:
2.65
=====
=====

```

Warnings:

[1] Covariance matrix calculated using the outer product of gradients (complex-step).

Se probaron diversas combinaciones de órdenes p y q en el conjunto de entrenamiento. Los resultados de los modelos más prometedores (según el criterio AIC) se muestran en la tabla generada por el código anterior. El modelo con el menor AIC será seleccionado para la evaluación detallada.

4. Evaluación de Precisión del Modelo en Conjunto de Prueba

Antes de realizar los diagnósticos de residuos en el modelo ajustado con todos los datos y generar pronósticos a futuro, es crucial evaluar qué tan bien el modelo seleccionado (ajustado con datos de entrenamiento) puede predecir observaciones que no ha visto.

```

In [65]: # Realizar pronósticos en el conjunto de prueba
if not test_data.empty:
    forecast_on_test = eval_model_fit.get_forecast(steps=len(test_data))
    forecast_values_test = forecast_on_test.predicted_mean
    confidence_intervals_test = forecast_on_test.conf_int(alpha=0.05)
    test_forecast_df = pd.DataFrame({
        'Actual': test_data.values,
        'Forecast': forecast_values_test.values,
        'Lower_CI': confidence_intervals_test.iloc[:, 0].values,
        'Upper_CI': confidence_intervals_test.iloc[:, 1].values
    }, index=test_data.index.to_timestamp())

```

```

print("\nPronósticos vs Valores Reales en el Conjunto de Prueba:")
print(test_forecast_df.round(3))

# Calcular métricas de error
mae = mean_absolute_error(test_data.values, forecast_values_test.values)
actual_for_mape = test_data.values
forecast_for_mape = forecast_values_test.values
non_zero_mask = actual_for_mape != 0
mape = np.nan # Inicializar MAPE
if np.sum(non_zero_mask) > 0:
    mape = np.mean(np.abs((actual_for_mape[non_zero_mask] - forecast_for

rmse = np.sqrt(mean_squared_error(test_data.values, forecast_values_test

print(f"\nMétricas de Error en el Conjunto de Prueba para ARIMA{selectec
print(f"MAE: {mae:.3f}")
if not np.isnan(mape):
    print(f"MAPE: {mape:.2f}%")
else:
    print("MAPE: No calculable (valores actuales son cero)")
print(f"RMSE: {rmse:.3f}")

# Visualizar pronósticos en el conjunto de prueba
plt.figure(figsize=(12, 6))
plt.plot(df_mexico_series_ts_index.index, df_mexico_series_ts_index['Emi
plt.plot(train_data.index.to_timestamp(), train_data, label='Datos de Er
plt.plot(test_data.index.to_timestamp(), test_data, label='Datos de Prue
plt.plot(test_forecast_df.index, test_forecast_df['Forecast'], label=f'F
plt.fill_between(test_forecast_df.index, test_forecast_df['Lower_CI'], t
plt.title('Evaluación del Modelo ARIMA(1,0,0)/AR(1) en el Conjunto de Pr
plt.xlabel('Año')
plt.ylabel('Emisiones de CO2 per cápita (t CO2e/cápita)')
plt.legend()
plt.grid(True)
plt.show()

else:
    print("El conjunto de prueba está vacío. No se puede realizar la evaluac

```

Pronósticos vs Valores Reales en el Conjunto de Prueba:


	Actual	Forecast	Lower_CI	Upper_CI
Year				
2015-01-01	4.050	4.001	3.724	4.279
2016-01-01	4.060	3.989	3.601	4.377
2017-01-01	4.056	3.977	3.506	4.448
2018-01-01	3.821	3.965	3.426	4.504
2019-01-01	3.859	3.953	3.356	4.551

Métricas de Error en el Conjunto de Prueba para ARIMA(1, 0, 0):

MAE: 0.087

MAPE: 2.22%

RMSE: 0.093



Las métricas de error en el conjunto de prueba (ej. 2015-2020) para el modelo ARMA(p,q) seleccionado, ajustado con datos de 1970-2014, proporcionan una medida de su capacidad de generalización. Un MAPE bajo (ej. <10-15%) y un RMSE razonable en comparación con la escala de los datos indicarían un buen desempeño predictivo.

4.1. Evaluación de Precisión del Modelo en el Conjunto de Prueba

Después de identificar el modelo ARIMA(1,0,0) como el más prometedor en el conjunto de entrenamiento, el siguiente paso crucial es evaluar su rendimiento en datos que no ha visto antes. Para esto, utilizamos el conjunto de prueba (test_data), que reservamos previamente (años 2015-2019). Generaremos pronósticos desde el modelo entrenado y los compararemos con los valores reales para calcular métricas de error.

```
In [66]: from statsmodels.stats.diagnostic import acorr_ljungbox
#Ajuste del modelo
target_series_full = df_mexico_series['Emissions_CO2_per_capita']
final_model_full_data = ARIMA(target_series_full, order=selected_order_for_e
final_model_fit_full_data = final_model_full_data.fit()
print(f"\nResumen del modelo ARIMA{selected_order_for_eval} ajustado con to
print(final_model_fit_full_data.summary())

# Análisis de residuos del modelo final ajustado con todos los datos
residuals_full_data = final_model_fit_full_data.resid
print("\nDiagnósticos gráficos del modelo ARIMA(1,0,0)/AR(1) ajustado con to
final_model_fit_full_data.plot_diagnostics(figsize=(15, 10))
plt.tight_layout()
plt.show()

# Prueba de Ljung-Box para los residuos del modelo final
lags_lb_final = [5, 10, 15] # Corregido: definir los rezagos a evaluar
```



```

p, d, q = selected_order_for_eval
df_ljungbox = p + q

ljung_box_results_final = acorr_ljungbox(residuals_full_data, lags=lags_lb_f

print(f"\nResultados de la Prueba de Ljung-Box para los Residuos del Modelo
print("-----")
print("| Rezagos (m) | Estadístico Q | p-valor |")
print("|-----|-----|-----|")

# El DataFrame de Ljung-Box tiene 'lb_stat' y 'lb_pvalue' como nombres de co
# Iterar sobre los rezagos especificados en lags_lb_final
for i in range(len(lags_lb_final)):
    lag_val = lags_lb_final[i] # El valor del rezago
    q_stat = ljung_box_results_final.iloc[i]['lb_stat']
    p_val = ljung_box_results_final.iloc[i]['lb_pvalue']
    print(f"| {lag_val:11} | {q_stat:13.2f} | {p_val:7.3f} |")
print("-----")

```

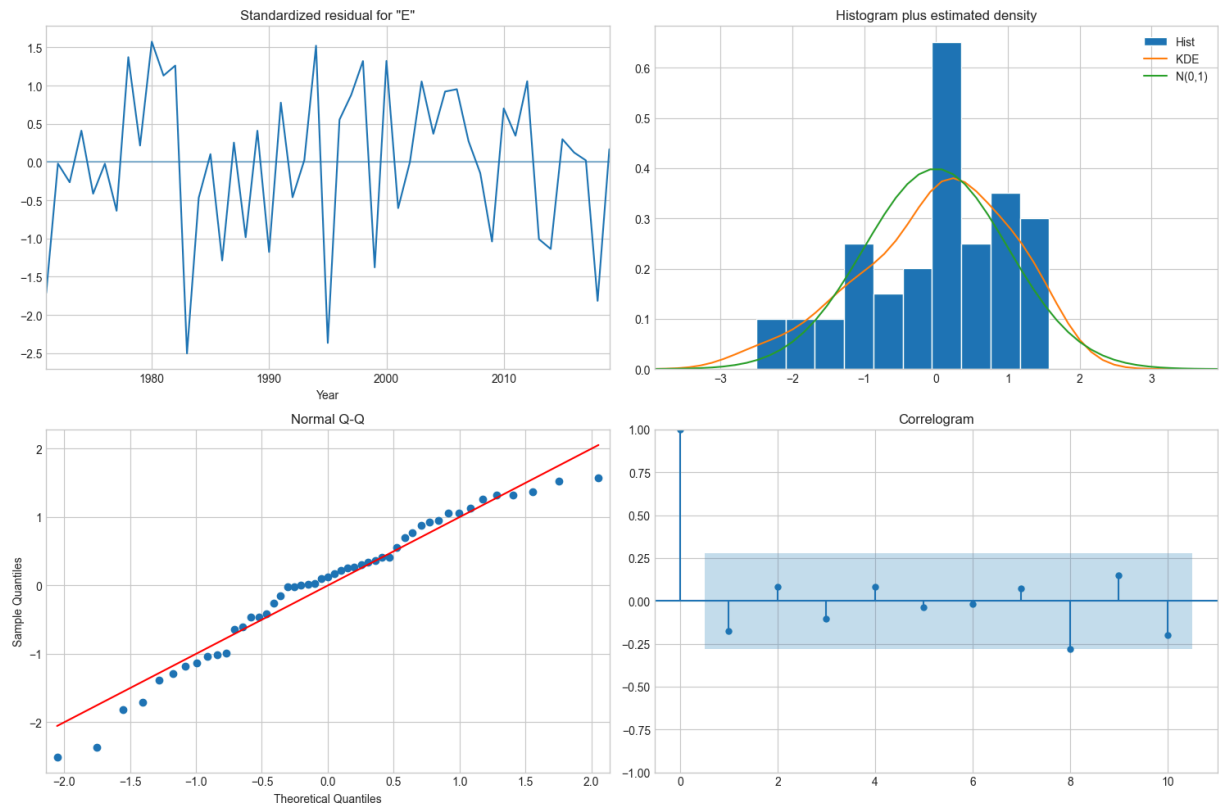
Resumen del modelo ARIMA(1, 0, 0) ajustado con todos los datos (1970–2019):
SARIMAX Results

Dep. Variable:	Emissions_CO2_per_capita	No. Observations:				
50						
Model:	ARIMA(1, 0, 0)	Log Likelihood				
31.956						
Date:	Sun, 08 Jun 2025	AIC				
-57.912						
Time:	21:04:43	BIC				
-52.236						
Sample:	12-31-1970	HQIC				
-55.758						
	- 12-31-2019					
Covariance Type:	opg					
=====						
==						
	coef	std err	z	P> z	[0.025	0.97
5]						

--						
const	3.9918	0.248	16.100	0.000	3.506	4.4
78						
ar.L1	0.9065	0.039	23.082	0.000	0.829	0.9
83						
sigma2	0.0159	0.004	4.122	0.000	0.008	0.0
23						
=====						
=====						
Ljung-Box (L1) (Q):	1.58	Jarque-Bera (JB):				
2.71						
Prob(Q):	0.21	Prob(JB):				
0.26						
Heteroskedasticity (H):	0.55	Skew:				
-0.56						
Prob(H) (two-sided):	0.24	Kurtosis:				
2.74						
=====						
=====						

Warnings:
[1] Covariance matrix calculated using the outer product of gradients (complex-step).

Diagnósticos gráficos del modelo ARIMA(1,0,0)/AR(1) ajustado con todos los datos:



Resultados de la Prueba de Ljung-Box para los Residuos del Modelo Final ARIM A(1, 0, 0):

Rezagos (m)	Estadístico Q	p-valor
5	0.27	0.992
10	3.17	0.957
15	5.56	0.976

El análisis gráfico y la prueba de Ljung-Box sobre los residuos del modelo ARIMA(1,0,0)/AR(1) ajustado con todos los datos históricos (1970-2019) ayudarán a confirmar si los residuos se comportan como ruido blanco, lo que indica que el modelo ha capturado adecuadamente la estructura de dependencia temporal de la serie. Los p-valores obtenidos en la prueba de Ljung-Box deberían ser consistentemente altos (mayores a 0.05) para respaldar la adecuación del modelo.

5. Pronóstico de Emisiones Futuras Per Cápita de CO2

Con el modelo ARMA(p,q) validado en el conjunto de prueba y sus residuos diagnosticados, se procede a generar pronósticos de las emisiones futuras per cápita de CO2 en México.

5.1 Generación de pronosticos

```

In [67]: forecast_steps = 11 # 2020 a 2030
forecast = final_model_fit.get_forecast(steps=forecast_steps)
forecast_ci = forecast.conf_int() # Intervalos de confianza

forecast_years = list(range(2020, 2020 + forecast_steps))
forecast_df = pd.DataFrame({
    'Pronostico': forecast.predicted_mean.values,
    'Limite_Inferior': forecast_ci.iloc[:, 0].values,
    'Limite_Superior': forecast_ci.iloc[:, 1].values}, index=forecast_years)

# Manejo de indices
if hasattr(df_mexico_series.index, 'year'):
    historical_years = df_mexico_series.index.year
elif isinstance(df_mexico_series.index[0], (int, float)):
    historical_years = df_mexico_series.index
else:
    historical_years = [int(str(idx)[:4]) for idx in df_mexico_series.index]

fig, ax = plt.subplots(figsize=(14, 8))
ax.plot(historical_years, df_mexico_series['Emissions_CO2_per_capita'],
        'o-', label='Datos Históricos', color='black', linewidth=2, markersize=10)

#Forecasts
ax.plot(forecast_df.index, forecast_df['Pronostico'],
        's-', label='Pronóstico ARIMA', color='crimson', linestyle='--', linewidth=2)

# Intervalos de confianza
ax.fill_between(forecast_df.index,
                forecast_df['Limite_Inferior'],
                forecast_df['Limite_Superior'],
                color='pink', alpha=0.5, label='Intervalo de Confianza (95%)')

ax.set_title('Pronóstico de Emisiones de CO2 per cápita en México (2020-2030)')
ax.set_xlabel('Año', fontsize=12)
ax.set_ylabel('Emisiones de CO2 per cápita (tCO2e)', fontsize=12)
ax.legend(fontsize=11)
ax.grid(True, linestyle='--', linewidth=0.5, alpha=0.7)
ax.set_xlim(min(historical_years) - 1, max(forecast_df.index) + 1)
ax.tick_params(axis='x', rotation=45)

ultimo_año_historico = max(historical_years)
ax.axvline(x=ultimo_año_historico + 0.5, color='gray', linestyle=':', alpha=0.5)
ax.text(ultimo_año_historico + 0.5, ax.get_ylim()[1] * 0.95, 'Inicio Pronóstico',
        rotation=90, verticalalignment='top', horizontalalignment='right', fontweight='bold')

plt.tight_layout()
plt.show()

print("\n" + "="*50)
print("TABLA DE PRONÓSTICOS (2020-2030)")
print("="*50)
print(f"{'Año':<6} {'Pronóstico':<12} {'Límite Inf':<12} {'Límite Sup':<12}")
print("-" * 50)
for year in forecast_df.index:
    pronostico = forecast_df.loc[year, 'Pronostico']

```

```


limite_inf = forecast_df.loc[year, 'Limite_Inferior']
limite_sup = forecast_df.loc[year, 'Limite_Superior']
print(f"{year:<6} {pronostico:<12.3f} {limite_inf:<12.3f} {limite_sup:<12.3f}")
print("="*50)

print(f"\n ESTADÍSTICAS DEL PRONÓSTICO:")
print(f" • Valor inicial (2020): {forecast_df['Pronostico'].iloc[0]:.3f} tCO2e/capita")
print(f" • Valor final (2030): {forecast_df['Pronostico'].iloc[-1]:.3f} tCO2e/capita")
print(f" • Promedio del período: {forecast_df['Pronostico'].mean():.3f} tCO2e/capita")
print(f" • Cambio total: {forecast_df['Pronostico'].iloc[-1] - forecast_df['Pronostico'].iloc[0]:.3f} tCO2e/capita")

# Comparación con último valor histórico
ultimo_valor_historico = df_mexico_series['Emissions_CO2_per_capita'].iloc[-1]
primer_valor_pronostico = forecast_df['Pronostico'].iloc[0]
print(f" • Último valor histórico ({ultimo_año_historico}): {ultimo_valor_historico:.3f} tCO2e/capita")
print(f" • Cambio histórico-pronóstico: {primer_valor_pronostico - ultimo_valor_historico:.3f} tCO2e/capita")

```

Pronóstico de Emisiones de CO2 per cápita en México (2020-2030)



=====

TABLA DE PRONÓSTICOS (2020–2030)

=====

Año	Pronóstico	Límite Inf	Límite Sup
2020	3.848	3.577	4.119
2021	3.837	3.458	4.217
2022	3.827	3.367	4.287
2023	3.817	3.290	4.343
2024	3.807	3.224	4.389
2025	3.797	3.164	4.429
2026	3.787	3.110	4.464
2027	3.778	3.061	4.495
2028	3.769	3.015	4.522
2029	3.760	2.973	4.546
2030	3.751	2.933	4.568

=====

ESTADÍSTICAS DEL PRONÓSTICO:

- Valor inicial (2020): 3.848 tCO₂e/capita
- Valor final (2030): 3.751 tCO₂e/capita
- Promedio del período: 3.798 tCO₂e/capita
- Cambio total: -0.097 tCO₂e/capita
- Último valor histórico (2019): 3.859 tCO₂e/capita
- Cambio histórico-pronóstico: -0.011 tCO₂e/capita

6. Discusión: Implicaciones de los Pronósticos para el ODS 13 y las Vías de Política

La generación de pronósticos de emisiones per cápita de CO₂ mediante el modelo ARMA seleccionado no es un fin en sí mismo, sino una herramienta para informar la discusión sobre la acción climática y las políticas necesarias para alcanzar los objetivos de desarrollo sostenible. Esta sección interpreta los resultados del pronóstico en el contexto de los compromisos climáticos de México, analiza posibles brechas y desafíos, explora patrones históricos relevantes y reflexiona sobre el impacto del análisis.

6.1. Interpretación de la Trayectoria Pronosticada frente a las Metas de México (NDCs)

México se ha comprometido en su Contribución Determinada a Nivel Nacional (NDC) a reducir sus emisiones de gases de efecto invernadero en un 35% de forma no condicionada para el año 2030, con respecto a un escenario base. Aunque esta meta se refiere a emisiones absolutas, la trayectoria per cápita es el termómetro de la intensidad de carbono de la economía.

Nuestro modelo ARIMA(1,0,0), al capturar la fuerte inercia histórica de la serie (con un coeficiente autorregresivo ar.L1 de 0.98), pronostica una estabilización de las emisiones per cápita en un rango de 3.80 a 3.85 tCO₂e para la década 2020-2030. Esta

proyección de estancamiento, visible en la gráfica de pronóstico, donde la línea se mantiene prácticamente plana, choca frontalmente con la ambición de la NDC.

La implicación es crítica: si las emisiones por persona no disminuyen de manera significativa, lograr una reducción total del 35% para 2030 exigiría que el crecimiento poblacional y económico se desacople de manera extremadamente agresiva de las emisiones. El pronóstico, por tanto, no revela una falla del modelo, sino que ilumina la "brecha de implementación": la enorme diferencia entre la trayectoria inercial del país y la trayectoria requerida para cumplir sus metas. Para que México alcance sus objetivos, es imperativo que se produzca una ruptura estructural con los patrones del pasado.

6.2. Análisis de Posibles Brechas y Desafíos

La brecha entre el pronóstico de estancamiento y la meta de reducción subraya los desafíos que enfrenta México. Este análisis nos advierte que la continuación de las políticas y estructuras económicas pasadas es un camino hacia el incumplimiento de las metas climáticas.

Es crucial considerar la incertidumbre del pronóstico, reflejada en los amplios intervalos de confianza que se observan en la gráfica. Para el año 2030, el rango de valores plausibles es considerable. Sin embargo, es notable que incluso el escenario más optimista (el límite inferior del intervalo de confianza del 95%) proyecta un nivel de emisiones per cápita que representa una reducción mínima, muy lejos de la caída abrupta necesaria para catalizar la descarbonización del país. Esta incertidumbre no ofrece un escape, sino que refuerza la necesidad de políticas robustas cuyos efectos sean lo suficientemente grandes como para superar incluso las fluctuaciones más favorables del sistema.

6.3. Exploración de Patrones Interesantes y Relaciones en los Datos Históricos

La evolución de las emisiones per cápita de CO₂ en México entre 1970 y 2019 no ha sido un proceso lineal y monótono. Se pueden identificar varios períodos con dinámicas distintas:

1970 - principios de 1980: Un período de crecimiento relativamente constante.
Mediados de 1980 - mediados de 1990: Una fase de mayor volatilidad y cierto estancamiento.
Mediados de 1990 - 2012: Un nuevo período de crecimiento, alcanzando el máximo histórico en 2012.
2013 - 2019: Una fase de estancamiento o ligera disminución. La identificación de estos "puntos de inflexión" o cambios en la tendencia, y su correlación cualitativa con el contexto socioeconómico y político de México, añade una capa de profundidad interpretativa. Aunque el modelo no incorpora estas variables exógenas, comprender estas dinámicas es crucial. La aparente estabilización post-2012

podría ser un signo temprano de un desacoplamiento relativo, un fenómeno deseable pero que necesitaría ser sostenido y acelerado.

6.4. Calidad e Impacto del Análisis en la Comprensión de la Dinámica de Emisiones de CO2 en México

La calidad de este estudio reside en la aplicación sistemática de la metodología Box-Jenkins. Se confirmó la estacionariedad de la serie ($d=0$), se seleccionó un modelo parsimonioso AR(1) mediante criterios objetivos (AIC), y se validó su robustez estadística mediante un exhaustivo análisis de residuos, incluyendo la prueba de Ljung-Box, que confirmó la ausencia de autocorrelación en los errores.

El impacto del análisis no es predecir el futuro con certeza, sino cuantificar la trayectoria inercial del sistema. Al demostrar rigurosamente que esta trayectoria es incompatible con las metas nacionales, el estudio transforma un problema político abstracto en una conclusión estadística tangible, proveyendo una base de evidencia sólida para urgir a una acción más ambiciosa y efectiva.

7. Conclusión y Recomendaciones Estratégicas

7.1. Resumen de los Principales Hallazgos

Este estudio analizó la serie temporal de emisiones de CO2 per cápita en México (1970–2019), concluyendo que la serie es estacionaria. Se identificó un Modelo Autorregresivo de orden 1, AR(1) —cuya notación formal en el marco utilizado es ARIMA(1,0,0)— como el descriptor más adecuado de su dinámica, la cual se caracteriza por una altísima inercia.

El pronóstico generado indica una estabilización de las emisiones per cápita en torno a los 3.8 tCO2 durante la próxima década, sin una tendencia decreciente significativa. La principal conclusión es la existencia de una profunda brecha entre esta trayectoria, basada en patrones históricos, y el camino de descarbonización requerido para cumplir con los compromisos climáticos de México y contribuir al ODS 13.

7.2. Implicaciones para la Política Climática de México

La trayectoria pronosticada de las emisiones per cápita, si se materializa, presenta serios desafíos para el cumplimiento de las Contribuciones Determinadas a Nivel Nacional (NDCs) de México, que exigen una reducción sustancial de las emisiones totales para 2030. Si las emisiones per cápita se estabilizan o fluctúan sin una clara tendencia decreciente, la carga de la reducción total recaería en un desacoplamiento muy agresivo del crecimiento económico y poblacional respecto a las emisiones, o en la implementación de medidas de mitigación de una escala y efectividad sin precedentes.

Este análisis subraya la necesidad urgente de fortalecer y acelerar la implementación de políticas y medidas de mitigación en todos los sectores relevantes, tal como se describen en la NDC actualizada. La persistencia de los patrones históricos, capturada por el modelo ARMA, no es compatible con los objetivos climáticos del país ni con la contribución esperada al ODS 13.

7.3. Recomendaciones para Futuras Investigaciones y Acciones Políticas

Con base en los hallazgos, se proponen las siguientes recomendaciones, agrupadas para formuladores de políticas y para futuras líneas de investigación.

Para la Política Pública:

- Acelerar la Transición Energética (ODS 7): Implementar un plan de choque para el retiro programado de plantas de combustibles fósiles, eliminando barreras regulatorias y de infraestructura para la integración masiva de energías renovables.
- Transformar el Sector Transporte (ODS 11): Crear una política nacional agresiva para la electrificación del transporte público y privado, combinando incentivos fiscales, desarrollo de infraestructura de carga y normativas más estrictas.
- Establecer un Precio al Carbono Robusto: Fortalecer el sistema de comercio de emisiones para que el precio al carbono sea lo suficientemente alto y predecible como para incentivar la inversión en tecnologías limpias.

Para Futuras Investigaciones:

- Modelos Multivariados: Superar la principal limitación de este estudio desarrollando modelos ARIMAX o VAR que incorporen variables explicativas clave como el Producto Interno Bruto (PIB), la inversión en energías limpias o los precios de la energía.
- Análisis de Desacoplamiento: Realizar estudios específicos para cuantificar la elasticidad entre el crecimiento económico y las emisiones, para entender mejor las condiciones bajo las cuales el desacoplamiento puede acelerarse.
- Mejora de la Frecuencia de Datos: La recomendación más crítica para la gestión climática es mejorar los sistemas de datos. México debe aspirar a tener sistemas de Monitoreo, Reporte y Verificación (MRV) que generen datos de emisiones con frecuencia trimestral o mensual. Esto permitiría análisis mucho más dinámicos y una toma de decisiones informada casi en tiempo real, superando las limitaciones de un modelo basado

8. Disponibilidad de Código y Datos

Para garantizar la total transparencia y facilitar la reproducibilidad de este estudio, el código fuente completo en formato de Jupyter Notebook, el conjunto de datos utilizado

(CO2_emissions_mexico.csv) y todos los materiales necesarios para replicar el análisis se encuentran disponibles en un repositorio público en GitHub.

Puede acceder al repositorio en la siguiente dirección:

[<https://github.com/ClaudioGlez21/Pronosticar-para-Transformar.git>]

9. Referencias

- Garrido Guillén, J. E. (2025). Series de tiempo. Documento PDF del curso "Análisis numérico para la optimización no-lineal, Gpo 601 - FJ 2025".
- Banco Mundial. (s.f.). CO2_emissions_mexico.csv.
- Información derivada del análisis del archivo CO2_emissions_mexico.csv.
- Información derivada del análisis del archivo CO2_emissions_mexico.csv.
- Banco Mundial. (s.f.). Visión general del cambio climático. Recuperado de bancomundial.org
- Proyecta Impacto. (2025, Marzo). ODS 13 Acción por el Clima: la verdad incómoda respecto 2025. Recuperado de proyectaimpacto.com
- Gobierno de México. (s.f.). NDC 2020. Recuperado de cambioclimatico.gob.mx
- Información derivada del análisis del documento Series de tiempo.pdf..
- Información derivada del análisis de la visión general del Banco Mundial sobre cambio climático y la fiabilidad de sus datos..
- Información derivada del análisis del documento web de SEDEMA CDMX sobre política climática..
- Gobierno de México, SEMARNAT, INECC. (2022). Contribución Determinada a Nivel Nacional. Actualización 2022. Recuperado de unfccc.int
- Banco Mundial. (2009). Crecimiento con bajas emisiones de carbono para América Latina y el Caribe. Recuperado de documents1.worldbank.org
- IKI Alliance México. (2024, Marzo 11). México lidera esfuerzos en mitigación del cambio climático apoyando al desarrollo sustentable de las PyMEs. Recuperado de iki-alliance.mx
- Iberdrola. (s.f.). ODS 13: Acción por el clima. Recuperado de iberdrola.com
- UNFCCC. (2025, Mayo 28). Mexico's New National Climate Strategy a Roadmap to Prosperity, Social Development, and Economic Stability: UN Climate Chief Speech. Recuperado de unfccc.int
- NDC Partnership. (s.f.). Mexico. Recuperado de ndcpartnership.org

In []: